

PENERAPAN MULTIMODEL DEEP LEARNING DALAM Pendeteksian Berita Hoaks Laman “TURNBACKHOAX.ID” MENGGUNAKAN ARSITEKTUR CNN

Ahmad Rizal Bayhaqi, Mukti Ratna Dewi, dan Mochammad Reza Habibi.
 Departemen Statistika Bisnis, Fakultas Vokasi, Institut Teknologi Sepuluh Nopember
 Kampus ITS Sukolilo-Surabaya 60111, Indonesia
e-mail: ahmad.rizal789.arb@gmail.com

Abstrak—Meningkatnya penyebaran berita hoaks memicu kebutuhan publik untuk mengatasi permasalahan tersebut. Masyarakat Anti Fitnah Indonesia (Mafindo), sebagai komunitas independen, berupaya memberikan edukasi dan identifikasi terkait berita hoaks. Meski demikian, proses verifikasi berita yang masih manual dan tidak cukup efektif mengingat jumlah berita hoaks yang tersebar cepat dan dalam jumlah besar. Oleh karena itu, penelitian dilakukan untuk membangun model *machine learning* menggunakan *deep learning*, khususnya *convolutional neural network* (CNN), dalam mengklasifikasikan berita hoaks secara cepat dan otomatis. Penggunaan CNN berbasis data teks dan gambar telah menunjukkan performa klasifikasi yang baik, terutama ketika kedua data digabungkan dalam *multimodel deep learning*. *Multimodel deep learning* atau model CNN gabungan, menggabungkan model CNN berbasis teks (CNN 1D) dan gambar (CNN 2D) yang menunjukkan kinerja lebih baik dibandingkan dengan model tunggal (*unimodel*). Model tersebut kemudian dilatih dengan 3103 data *training* dan 775 data *testing* dan diperoleh nilai akurasi 99,35% dan AUC 99,81%. Hasil evaluasi menunjukkan kinerja yang baik dalam mengklasifikasikan berita hoaks di dalam dan di luar model.

Kata Kunci— CNN, Hoax, Multimodel Deep Learning.

I. PENDAHULUAN

Informasi atau berita yang banyak tersebar di internet tidak semuanya dapat dipercaya, sebagian informasi dibuat untuk tujuan menyesatkan pembaca oleh pihak tak bertanggung jawab, dengan kata lain disebut hoaks. Hoaks merujuk pada kabar, berita, informasi palsu atau bohong yang sengaja disebarluaskan untuk mencapai tujuan tertentu. Terdapat beberapa alasan atau faktor penyebab munculnya berita hoaks, yaitu sebagai hiburan, meramaikan perkembangan tren di internet, mencari sensasi, dan sebagai pekerjaan untuk menyudutkan pihak tertentu [1]. Saat ini persebaran berita hoaks sangat luas dan mudah dijumpai dalam kehidupan sehari-hari. Mengutip publikasi Kementerian Komunikasi dan Informatika (Kominfo), sepanjang tahun 2018 setidaknya ada 800.000 situs internet penyebar hoaks dan triwulan pertama tahun 2023 Kominfo telah mengidentifikasi sebanyak 425 isu hoaks yang beredar melalui website di tanah air [2]. Sementara hasil survei yang dilakukan Katadata Insight Center (KIC) bersama Kominfo menunjukkan bahwa 30%-60% masyarakat indonesia terpapar berita hoaks saat beraktivitas di dunia maya [3].

Berita hoaks menyebar dengan sangat cepat dan merupakan permasalahan serius di Indonesia. Hoaks merugikan

berbagai sektor kehidupan serta mengganggu kenyamanan dan keamanan masyarakat. [4]. Dampak negatif berita hoaks juga dapat memecah belah publik dan memicu ujaran kebencian terhadap individu hingga kelompok atau lembaga tertentu [5]. Seperti yang terjadi pada kasus rasisme terhadap mahasiswa Papua di Surabaya yang dipicu oleh berita hoaks yang disebar melalui media sosial. Berita tersebut dibagikan oleh Tri Susanti melalui *whatsapp group* dengan narasi bahwa mahasiswa Papua merobek dan mematahkan tiang bendera merah putih, hingga pada akhirnya memicu ketegangan antar kelompok ormas setempat dan mahasiswa Papua di Surabaya [6]. Tragedi rasisme terhadap mahasiswa Papua menunjukkan penyebaran berita sangat cepat melalui media sosial dan memberikan dampak yang signifikan terhadap masyarakat. Berbeda dengan berita konvensional dan berita untuk melawan hoaks, dimana penerbitan keduanya harus melewati proses kaidah jurnalistik, sementara berita hoaks bisa dilakukan oleh siapa saja dengan konten apa saja tanpa melalui proses kaidah jurnalistik [7]. Keterbatasan tersebut yang membuat berita hoaks dapat tersebar secara masif mengungguli berita konvensional saat ini, sangat berbahaya, dan sulit untuk diverifikasi [8].

Upaya menekan persebaran berita hoaks dilakukan oleh pemerintah melalui Kominfo dan kelompok-kelompok masyarakat salah satunya Masyarakat Anti Fitnah Indonesia (Mafindo). Mafindo merupakan gerakan komunitas independen yang bergerak di bidang literasi dan edukasi masyarakat mengenai hoaks, Mafindo didirikan untuk meminimalisasi penyebaran informasi bohong (hoaks) di media sosial [9]. Dalam upaya menekan persebaran hoaks akibat perkembangan teknologi media sosial Mafindo membangun komunitas media sosial dan membangun website *turnbackhoax.id*. Melalui website *turnbackhoax.id*, Mafindo berfokus membagikan informasi hoaks yang sudah diverifikasi. Namun proses verifikasi suatu informasi atau berita saat ini masih dilakukan secara manual, dimana kecepatan prosesnya tidak sebanding dengan jumlah persebaran berita hoaks yang masif beredar di masyarakat. Jika tidak segera diatasi, penyebaran berita hoaks akan semakin luas serta pihak pemerintah dan Mafindo akan tertinggal, serta tidak mampu memberi penanganan secara maksimal.

Mengatasi permasalahan berita hoaks yang menyebar cepat di media sosial dan jumlahnya yang masif dapat diselesaikan dengan bantuan mesin. Penggunaan mesin akan membuat proses klasifikasi dapat berjalan secara otomatis,

tidak lagi manual, dan tidak memakan banyak waktu [10]. Mesin klasifikasi berita hoaks dan fakta dapat dibangun menggunakan berbagai jenis model, contohnya model *deep learning*. Model *deep learning* (DL) merupakan salah satu jenis model yang banyak digunakan dalam tugas mendeksi teks, citra digital, pengenalan suara, dan lain-lain [11]. Kebanyakan model DL dirancang untuk fokus pada pengolahan satu jenis data (*unimodel*) semisal mengolah teks saja atau gambar saja. Dalam kasus model klasifikasi berita penggunaan model berbasis teks paling banyak digunakan dalam klasifikasi berita hoaks dan fakta berbahasa indonesia.

Penggunaan model klasifikasi tunggal (*unimodel*) dapat ditingkatkan dengan menggunakan gabungan model berbasis teks dan model berbasis gambar (*multimodel*). Menurut Triasa dan Herlina bahwa penggunaan *news photo or caption* (foto berita) pada berita hoaks mampu memengaruhi emosi pembaca. Foto berita mempengaruhi emosi pembaca melalui dua hal yaitu, foto berita sebagai bukti atas terjadinya sebuah peristiwa serta foto sebagai pembangkit beragam emosi untuk membuat orang lebih mudah memercayai hoaks [12]. Berdasarkan penelitian tersebut menambahkan foto berita memiliki kemungkinan untuk meningkatkan model dalam mengklasifikasi berita hoaks dan fakta. Sementara hasil gabungan dua model berbasis teks dan gambar tersebut disebut *multimodel deep learning*. Penelitian yang dilakukan Li dkk. menjelaskan penggunaan *multimodel deep learning* pada berita satir di Amerika Serikat menunjukkan performa *multimodel* lebih baik dibanding model dengan foto berita saja atau text saja [13]. Penelitian-penelitian di atas menjadi dasar untuk mengembangkan *multimodel deep learning* pada foto berita dan text berbahasa indonesia untuk mengidentifikasi berita hoaks dan fakta. Adapun penggunaan *multimodel deep learning* dengan arsitektur *convolution Neural network* (CNN) memiliki performa unggul dibanding arsitektur lain dalam mengklasifikasikan berita hoaks berbahasa Indonesia [14]. Diharapkan penggunaan *multimodel deep learning* dengan arsitektur CNN menjadi solusi mengimbangi persebaran berita hoaks yang masif.

Berdasarkan permasalahan dan penelitian-penelitian sebelumnya, penelitian ini bertujuan untuk membangun model klasifikasi berita hoaks dan fakta berbahasa indonesia menggunakan *multimodel deep learning* yang berbasis pada berita di laman *turnbackhoax.id*. *Multimodel deep learning* menggunakan teks dan foto berita dari berita sebagai input dalam bentuk vektor. Model diharapkan dapat dimanfaatkan untuk melakukan prediksi apabila terdapat berita atau laporan informasi baru yang masuk. Klasifikasi berita dengan model akan berjalan secara otomatis dan terstruktur untuk mengidentifikasi kebenaran suatu berita, sehingga mempercepat proses kerja deteksi dan verifikasi berita yang tersebar di masyarakat dan media sosial *positioning*.

II. TINJAUAN PUSTAKA

A. Studi Literatur

Penelitian terkait klasifikasi berita hoaks sudah pernah dilakukan menggunakan berbagai pendekatan dan metode *machine learning*. Berikut ringkasan penelitian terdahulu

terkait klasifikasi berita hoaks menggunakan model *machine learning* dan *deep learning*.

1. Penelitian yang dilakukan oleh Yuliani dan Sahib, yaitu membandingkan performa klasifikasi berita hoaks dari enam algoritma ML menunjukkan model *neural network* (NN) memiliki hasil akurasi terbaik sebesar 93,33%. Sedangkan model *support vektor machine* (SVM), *naive bayes*, *decision tree*, *logistic regression* nilai akurasi tidak lebih besar dari 91% [15].
2. Penelitian terhadap penggunaan teks dan gambar untuk meningkatkan kemampuan model klasifikasi tanggap bencana oleh Ferda Olfi, model menunjukkan bahwa arsitektur *multimodel* yang diusulkan memberikan kinerja yang lebih baik daripada model yang dilatih menggunakan satu model saja (misalnya, teks atau gambar saja) [16].
3. Penelitian yang dilakukan oleh Antonius dan Metty dalam klasifikasi berita hoaks berbahasa Indonesia. Hasil penelitian menunjukkan akurasi model CNN sebesar 88%, sedangkan model LSTM 4% lebih rendah dibawah CNN [14].

B. Web scraping

Web scraping adalah proses pengambilan dokumen semi-terstruktur dari halaman web untuk mendapatkan data tertentu dari halaman tersebut. Teknik ini digunakan untuk mengekstraksi informasi dari situs web dan menyimpannya dalam file atau database untuk keperluan analisis data. *Web scraping* memungkinkan pengumpulan *big data* secara efisien dan kuat yang tidak dapat dilakukan oleh mesin pencari tradisional seperti Google Search. [19].

C. TF-IDF

TF-IDF adalah metode algoritma yang berguna untuk menghitung bobot dari setiap kata yang umum digunakan dalam sebuah dokumen. Metode ini menggabungkan nilai *Term Frequency* (TF) dan *Inverse Document Frequency* (IDF) untuk menghasilkan bobot yang menggambarkan seberapa pentingnya sebuah kata dalam sebuah dokumen [20]. Nilai TF mengukur seberapa sering sebuah kata muncul dalam sebuah dokumen, sedangkan IDF mengukur seberapa umum atau jarang sebuah kata dalam sebuah korpus. Persamaan untuk menghitung TF, IDF, dan TF-IDF memberikan pemahaman yang lebih mendalam tentang konsep ini. Persamaan (1) menggambarkan penghitungan TF, di mana $f_{k,d}$ merupakan frekuensi kata k dalam dokumen d . Persamaan (2) menjelaskan penghitungan IDF, dengan N adalah jumlah total dokumen dalam korpus dan df_k adalah jumlah dokumen yang mengandung kata k . Kemudian, persamaan (3) menggabungkan nilai TF dan IDF untuk menghitung TF-IDF, di mana $TF-IDF_{k,d}$ memberikan bobot yang lebih tinggi pada kata-kata yang muncul lebih sering dalam dokumen tetapi lebih jarang muncul dalam keseluruhan korpus teks. TF-IDF digunakan dalam berbagai tugas pemrosesan teks seperti klasifikasi teks, pencarian informasi, dan rekomendasi konten [21].

$$TF_{k,d} = \begin{cases} 1 + \log_{10}(f_{k,d}), & f_{k,d} > 0 \\ 0, & f_{k,d} = 0 \end{cases} \quad (1)$$

$$IDF_k = \begin{cases} \log\left(\frac{N}{df_k}\right), & N > df_k \\ \log\left(\frac{N}{df_k}\right) + 1, & N = df_k \end{cases} \quad (2)$$

$$TF - IDF_{k,d} = TF_{k,d} \times IDF_k \quad (3)$$

D. Deep Learning

Deep learning (DL) merupakan bagian dari *machine learning* (ML) yaitu, sebagai pembaruan dari *neural network multiple layer* yang merupakan salah satu algoritma ML [11]. Proses pembelajaran DL didasarkan pada ekstraksi fitur secara otomatis dan hierarkis melalui (NN), tanpa memerlukan ekstraksi fitur manual. *Deep learning* memungkinkan komputer membangun konsep kompleks dari yang lebih sederhana misalnya, sistem pengenal citra suatu objek [22]. DL dapat ditunjukkan dengan adanya *layer* untuk mengolah dan mempelajari fitur dalam membuat pola sebagai fitur baru. *Layer* tersebut merupakan lapisan ekstraksi fitur dimana salah satu contohnya menggunakan metode *convolution*.

Sementara itu *feature extraction* sendiri adalah proses pengambilan informasi paling relevan atau fitur-fitur penting dari data yang kompleks. Perbedaan mendasar antara feature extraction dalam ML konvensional dan DL terletak pada tingkat otomatisasi dan kemampuan memahami representasi fitur yang lebih kompleks pada DL. Dalam ML tradisional, manusia cenderung harus secara manual menentukan dan mengekstrak fitur-fitur yang dianggap penting, sementara dalam DL, NN mampu secara otomatis mengidentifikasi dan mengekstrak fitur-fitur tersebut dari data. Dengan demikian, DL memungkinkan penciptaan model yang lebih adaptif dan mampu mengatasi tugas-tugas kompleks, seperti pengenalan citra objek, dengan tingkat akurasi yang lebih tinggi.

E. Convolution, Padding, dan Stride

Convolution atau konvolusi adalah operasi matematis yang bekerja pada dua fungsi untuk menciptakan fungsi baru yang menggambarkan pola atau karakteristik. Fungsi pertama dapat menggambarkan nilai sebuah data input dalam bentuk matriks atau vektor. Sedangkan fungsi kedua merupakan fungsi pembobotan yang disebut kernel atau filter yang juga dalam bentuk matriks atau vektor. Konvolusi akan menghasilkan fungsi baru yang menggambarkan fitur atau pola berdasarkan hasil pembobotan [23]. Adapun konvolusi bertujuan untuk mempelajari representasi fitur dari data input. Data input akan dikonvolusikan dengan filter dan akan membentuk berbagai fitur. Masing-masing fitur menjadi dasar pembeda data satu dengan yang lain [24]. Dalam bentuk matematis kontinu, konvolusi dari dua fungsi $f(t)$ dan $g(t)$ dapat dinyatakan sebagai persamaan (4):

$$C(x) = f(x) * g(x) = \sum_{x=-\infty}^{\infty} \sum_{x=-\infty}^{\infty} f(x)g(x-t) \quad (4)$$

Persamaan (4) menunjukkan nilai $g(x)$ merupakan filter konvolusi atau filter yang berfungsi sebagai pemberi bobot nilai pada fungsi $f(x)$. Bobot nilai ditentukan secara acak dan jika suatu konvolusi memiliki lebih dari satu filter maka tiap filter akan menghasilkan bobot acak yang berbeda-beda. Hasil konvolusi $C(x)$ merupakan hasil dari perkalian dan jumlah kedua fungsi pada setiap elemen matriks dan nilainya berbeda untuk tiap filter yang digunakan.

Pada data dalam format vektor atau matriks hasil konvolusi mempengaruhi ukuran akhir dimensi dari vektor atau

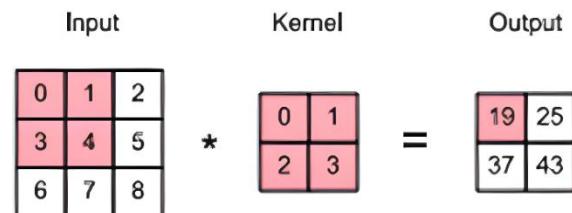
matriks berdasarkan dimensi filernya. Perbedaan dimensi terjadi karena proses konvolusi merupakan fungsi berjalan dari kiri ke kanan dan tambahan dari atas ke bawah untuk matriks. Untuk mengetahui bagaimana dimensi akhir suatu vektor atau matriks yang dilakukan konvolusi diperoleh menggunakan persamaan (5):

$$(n_h - k_h + 1) \times (n_w - k_w + 1) \quad (5)$$

Keterangan:

- n_h : Jumlah baris matriks data input (dimensi tinggi)
- n_w : Jumlah kolom matriks data input (dimensi panjang)
- k_h : Jumlah baris matriks filter (dimensi tinggi)
- k_w : Jumlah kolom matriks filter (dimensi panjang)

Menggunakan persamaan (5) dimensi matriks digambarkan dalam persamaan $n_h \times n_w$ dengan kernel berukuran $k_h \times k_w$, sementara vektor memiliki nilai n_h dan k_h sama dengan 1. Berikut ilustrasi dari konvolusi ditampilkan pada Gambar 1.



Gambar 1 Proses Convolution Layer

Dalam operasi konvolusi (*), terdapat parameter penting seperti *padding* dan *stride*. *Padding* merujuk pada penambahan nilai nol di sekitar tepi matriks, dalam konteks ini, gambar sebagai data input atau peta fitur. Penambahan nilai nol ini bertujuan untuk menjaga dimensi akhir matriks gambar atau peta fitur saat mengalami proses konvolusi. Berikut ilustrasi matriks dengan penambahan *padding* ditampilkan Gambar 2:

Gambar 2 (A) merupakan contoh matriks asli sebelum mendapat penambahan *padding*. Kemudian matriks (B) menunjukkan matriks asli yang telah mendapatkan penambahan *padding* dengan nilai 1. Sementara matriks (C) merupakan matriks asli dengan penambahan *padding* dengan nilai 2. Parameter selanjutnya merupakan *stride*, *stride* menunjukkan seberapa jauh filter bergeser selama proses konvolusi [25]. Stride dengan nilai satu akan menggerakkan filter satu kolom ketika mendatar dan satu baris ketika menurun selama proses konvolusi.

(A)	(B)	(C)																																																																																																											
<table border="1" style="border-collapse: collapse; width: 100px; height: 100px;"> <tr><td>1</td><td>0</td><td>9</td></tr> <tr><td>4</td><td>7</td><td>3</td></tr> <tr><td>5</td><td>4</td><td>8</td></tr> </table>	1	0	9	4	7	3	5	4	8	<table border="1" style="border-collapse: collapse; width: 100px; height: 100px;"> <tr><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td></tr> <tr><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td></tr> <tr><td>0</td><td>0</td><td>1</td><td>0</td><td>9</td><td>0</td><td>0</td></tr> <tr><td>0</td><td>0</td><td>4</td><td>7</td><td>3</td><td>0</td><td>0</td></tr> <tr><td>0</td><td>0</td><td>5</td><td>4</td><td>8</td><td>0</td><td>0</td></tr> <tr><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td></tr> <tr><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td></tr> </table>	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	9	0	0	0	0	4	7	3	0	0	0	0	5	4	8	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	<table border="1" style="border-collapse: collapse; width: 100px; height: 100px;"> <tr><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td></tr> <tr><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td></tr> <tr><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td></tr> <tr><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td></tr> <tr><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td></tr> <tr><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td></tr> <tr><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td><td>0</td></tr> </table>	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
1	0	9																																																																																																											
4	7	3																																																																																																											
5	4	8																																																																																																											
0	0	0	0	0	0	0																																																																																																							
0	0	0	0	0	0	0																																																																																																							
0	0	1	0	9	0	0																																																																																																							
0	0	4	7	3	0	0																																																																																																							
0	0	5	4	8	0	0																																																																																																							
0	0	0	0	0	0	0																																																																																																							
0	0	0	0	0	0	0																																																																																																							
0	0	0	0	0	0	0																																																																																																							
0	0	0	0	0	0	0																																																																																																							
0	0	0	0	0	0	0																																																																																																							
0	0	0	0	0	0	0																																																																																																							
0	0	0	0	0	0	0																																																																																																							
0	0	0	0	0	0	0																																																																																																							
0	0	0	0	0	0	0																																																																																																							

Gambar 2 Padding Pada Matriks

Proses penambahan *padding* dan *stride* tidak mengubah persamaan (5) jika digunakan secara *default*, yaitu ketika model memiliki *padding* nol dan *stride* satu. Namun, dengan menambahkan *padding* dan menggunakan *stride* yang berbeda,

dimensi vektor atau matriks akan mengalami perubahan berdasarkan persamaan (6):

$$\left(\frac{(n_h - k_h + p_h + s_h)}{s_h} \right) \times \left(\frac{(n_w - k_w + p_w + s_w)}{s_w} \right) \quad (6)$$

Keterangan:

p_h : Jumlah padding pada dimensi tinggi matriks data input

p_w : Jumlah padding pada dimensi panjang matriks data input

s_h : Jumlah stride filter ketika bergerak vertikal

s_w : Jumlah stride filter ketika bergerak horizontal

F. Multimodel Deep Learning

Multimodel deep learning merupakan model gabungan dua atau lebih model *deep learning*. *Multimodel deep learning* menjadi bidang yang semakin populer karena kemampuannya untuk mengintegrasikan data *heterogen* dalam satu arsitektur yang efektif [26]. Penerapan *multimodel deep learning* telah menunjukkan hasil yang baik dalam berbagai permasalahan, termasuk klasifikasi gambar objek yang memiliki kemiripan tinggi dengan menggabungkan informasi dari gambar dan teks. *Multimodel deep learning* dapat meningkatkan akurasi dan interpretabilitas dari model [27]. Secara keseluruhan, *multimodel deep learning* telah membuka pintu bagi penggabungan berbagai jenis data untuk meningkatkan kinerja model dan memberikan wawasan yang lebih jelas tentang bagaimana *model deep learning* membuat keputusan.

III. METODOLOGI PENELITIAN

A. Sumber Data

Data yang digunakan pada penelitian ini merupakan data sekunder yang diperoleh dari website *turnbackhoax.id*, sebagai sumber berita hoaks dan *republika.co.id* sebagai sumber berita fakta. Data diambil menggunakan proses *web scraping* pada berita hoaks dan fakta selama periode publikasi tanggal 1 Januari 2023 hingga 13 Oktober 2023. Waktu pengambilan data dilakukan pada hari Kamis, 13 Oktober 2023 pukul 09.00 secara online.

B. Variabel Penelitian

Variabel penelitian yang digunakan dalam penelitian ini diuraikan dalam Tabel 1:

Tabel 1. Variabel Penelitian

Variabel	Keterangan	Skala	Kategori
X_1	News Picture atau gambar berita pada berita yang diterbitkan <i>turnbackhoax.id</i> dan <i>republika.co.id</i> . Gambar merupakan matriks dengan nilai elemen antara (0,225)	Interval	-
X_2	Konten atau teks berita pada berita yang diterbitkan <i>turnbackhoax.id</i> dan <i>republika.co.id</i> . Teks merupakan kumpulan kata atau token tanpa tingkatan	Nominal	-
Y	Label berita pada berita yang diterbitkan <i>turnbackhoax.id</i> dan <i>republika.co.id</i>	Nominal	1: Hoaks 0: Bukan Hoaks

C. Teknik Scrapping dan Data Labeling

Pada tahap *scrapping* (pengumpulan data), metode *web scraping* dijalankan untuk mengakses laman *turnbackhoax.id* dan *republika.co.id*, kemudian mengambil konten dari masing-masing laman. Proses ini melibatkan permintaan HTTP menggunakan *library requests* untuk mengakses laman, kemudian menerjemahkan kode konten HTML menggunakan *library python* yaitu *Beautiful Soup*. Hasil ekstraksi disusun dengan indeks berdasarkan publikasi berita terbaru, dimana indeks pertama merupakan laman *turnbackhoax.id* publikasi 13 Oktober 2023 dan indeks terakhir merupakan laman *republika.co.id* publikasi 1 Januari 2023. Proses ini mengumpulkan data berita berupa tanggal terbit, judul berita, foto berita, dan konten berita yang akan menjadi bahan analisis selanjutnya.

Setelah data berita terkumpul, dilakukan proses *data labeling* (pelabelan data) untuk mengidentifikasi berita hoaks dan fakta. Berita hoaks dapat diidentifikasi berdasarkan kata kunci yang tertera pada setiap judul berita *turnbackhoax.id*, dimana pihak MAFINDO telah berfokus mengidentifikasi berita hoaks yang kemudian dipublikasikan melalui laman tersebut. Setiap judul berita akan diperiksa, jika kata kunci yang merujuk berita hoaks ditemukan maka, berita diberi label sesuai kata kunci. Kata kunci merupakan kata yang diletakkan di awal judul berita pada laman *turnbackhoax.id*. Untuk kata kunci “SALAH”, “HOAX”, dan “PALSU” akan diberi label sebagai berita hoaks dan dikategorikan dengan angka 1. Sementara berita dengan label fakta dan dikategorikan dengan angka 0 merujuk pada berita yang tidak berlabel hoaks.

Proses *data labeling* dilakukan secara otomatis menggunakan *python* dengan bantuan *library regex*. *Regex* akan mengidentifikasi setiap kata pertama pada tiap judul kemudian membuat kolom yang berisikan hasil penentuan label. Data yang telah diberi label selanjutnya disimpan dalam format Excel menggunakan *library pandas* dan disimpan dalam format file *xlsx* untuk memudahkan akses dalam melakukan analisis.

D. Langkah Analisis

Penelitian ini mengikuti langkah-langkah analisis sebagai berikut:

1. Pengumpulan Data: Data berita dari *turnbackhoax.id* dan *republika.co.id* dikumpulkan dan diberi label sebagai hoaks atau fakta.
2. Pre-processing Data: Data teks dan gambar dibersihkan dan diolah. Ini mencakup penghapusan data tidak lengkap, penghapusan *stopwords*, tokenisasi, *lemmatizing*, dan normalisasi nilai pixel pada gambar.
3. Pembagian Data: Data dibagi menjadi data training dan testing dengan rasio 8:2 menggunakan metode *holdout*.
4. Pembangunan Model CNN: Tiga model CNN dibangun: model teks, model gambar, dan model gabungan teks dan gambar. Setiap model memiliki lapisan input, konvolusi, *pooling*, *flattening*, *fully connected*, dan output.
5. Pelatihan Model: Model-model CNN dilatih menggunakan data *training* dan dievaluasi

- menggunakan data testing. Model-model lain seperti SVM dan regresi logistik juga dilatih untuk perbandingan.
6. Evaluasi Model: Model-model dievaluasi berdasarkan akurasi dan AUC dari ROC. Model terbaik dipilih untuk mengklasifikasikan berita hoaks dan fakta.
 7. Kesimpulan dan Saran: Hasil evaluasi digunakan untuk menarik kesimpulan dan memberikan saran.

IV. ANALISIS DAN PEMBAHASAN

A. Hasil Scrapping dan Labeling Berita

Dari hasil pengumpulan data menggunakan metode *scrapping* dan *labeling* dari website *turnbackhoax.id* dan *republika.co.id*, diperoleh total 5165 data, dengan proporsi 33,71% merupakan berita hoaks dan 66,29% adalah berita fakta. Namun, terjadi ketidakseimbangan kategori data, di mana seluruh berita dari *turnbackhoax.id* dikategorikan sebagai hoaks, sementara berita dari *republika.co.id* mayoritas merupakan fakta. Setelah penanganan, jumlah data yang seimbang antara kategori hoaks dan fakta adalah 3878.

B. Preprocessing dan Pembagian Data

Pada tahap *preprocessing*, proses dimulai dengan eksplorasi data yang melibatkan penelitian mendalam terhadap struktur dan karakteristik data. Selanjutnya, dilakukan proses pembersihan data untuk menghapus data yang tidak lengkap dan melakukan penghapusan *stopwords*, tokenisasi, serta *lemmatizing* kata-kata ke bentuk dasarnya pada data teks. Data teks kemudian diubah menjadi vektor menggunakan metode TF-IDF, dengan panjang vektor yang ditetapkan sebanyak 8900 untuk memastikan keseimbangan antara akurasi dan efisiensi komputasi dalam model, tanpa mengorbankan akurasi yang signifikan. Data gambar foto berita kemudian diubah menjadi resolusi seragam 224×224 pixel. Selanjutnya, data dibagi menjadi data training dan testing menggunakan metode *Holdout*, di mana 80% data (3103) dipilih sebagai data training dan 20% data (775) sebagai data testing. Pembagian data yang dilakukan secara acak memastikan proporsi label hoaks dan fakta yang seimbang pada kedua set data.

C. Analisis Model Klasifikasi Berita Teks

Analisis model klasifikasi berita dilakukan dengan tiga model dimana model pertama berbasis teks menggunakan model CNN 1D. Model kemudian dilakukan *training* dan *testing* dimana nilai *loss* saat melatih data dan memvalidasi model CNN 1D menggunakan teks disajikan pada Gambar 3.

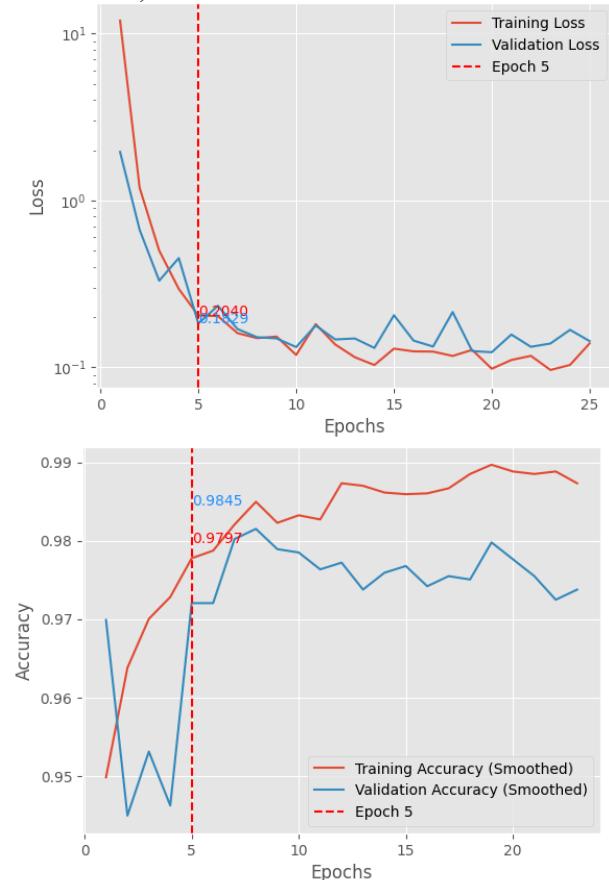
Gambar 3 menunjukkan gap nilai antara *loss* pada proses *training* dan *testing* (validasi) model CNN 1D memiliki gap yang semakin besar, dimana nilai validasi *loss* lebih tinggi dibandingkan *training* yang menunjukkan nilai *loss* lebih tinggi atau model mengalami *underfit*. Begitu juga gap nilai pada akurasi CNN 1D juga mengalami *underfit*, yaitu nilai akurasi validasi lebih rendah dibandingkan *training*. Untuk mengatasi *underfit* pada model dilakukan pengembalian nilai bobot pada epoch ke-37 yang memiliki nilai *loss* terkecil dan nilai akurasi terbesar. Epoch ke-37 diperoleh dari pelatihan model dengan 100 epoch dan akan otomatis berhenti setelah diperoleh 20 epoch yang tidak berbeda signifikan (*early stopping*) dan

mengembalikan epoch ke-37 sebagai bobot terbaik. Sehingga diperoleh nilai akurasi Model CNN 1D sebesar 82,32%.

D. Analisis Model Klasifikasi Berita Gambar

Analisis model klasifikasi berita berikutnya berbasis gambar atau menggunakan model CNN 2D. Model kemudian dilakukan *training* dan *testing* dimana nilai *loss* saat melatih data dan memvalidasi model CNN 2D menggunakan teks disajikan pada Gambar 4:

Gambar 4 menunjukkan hal yang sama seperti Gambar 3, yaitu gap nilai antara *loss* dan akurasi pada proses *training* dan *testing* model CNN 2D semakin besar sehingga model mengalami *underfit*. Kemudian dilakukan penanganan pengembalian nilai, dari 100 epoch *training* telah diperoleh 20 epoch yang tidak berbeda signifikan dan mengembalikan epoch ke-5 sebagai bobot terbaik. Sementara hasil pengembalian nilai model CNN 2D memberikan hasil lebih baik dibandingkan model CNN 1D dalam mengklasifikasikan berita hoaks dengan nilai sebesar 98,54%.



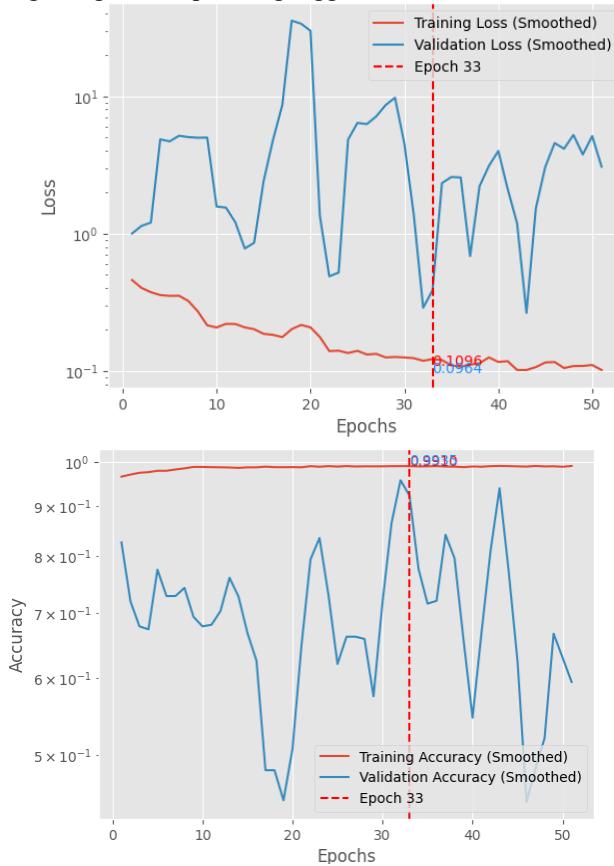
Gambar 4 Model 2D Loss (atas) dan Akurasi (bawah)

E. Analisis Model Klasifikasi Berita Teks dan Gambar

Analisis model klasifikasi berita terakhir yaitu model CNN gabungan menggunakan teks dan gambar. Model kemudian dilakukan *training* dan *testing* dimana nilai *loss* saat melatih data dan memvalidasi model CNN gabungan disajikan pada Gambar 5:

Sama seperti model CNN 1D dan 2D, Gambar 5 menunjukkan gap nilai antara *loss* dan akurasi pada proses *training* dan *testing* model CNN gabungan memiliki gap yang semakin besar sehingga menimbulkan *underfit*. Selanjutnya dilakukan pengamanan yang sama seperti kedua model

sebelumnya dimana dari 100 epoch telah diperoleh 20 epoch yang tidak berbeda signifikan dan mengembalikan epoch ke-33 sebagai bobot terbaik dengan nilai akurasi mencapai 99,35%. Selain itu proses pengembalian bobot memberikan hasil model CNN gabungan mampu mengungguli model CNN 1D dan 2D.



Gambar 5 Model CNN Kombinasi Loss (atas) dan Akurasi (bawah)

F. Evaluasi Model

Model klasifikasi berita hoaks dan fakta yang telah dibangun menggunakan tiga model berbasis data gambar, teks, dan gabungan keduanya, dievaluasi untuk menentukan model terbaik. Evaluasi ini didasarkan pada nilai akurasi dan AUC dari fungsi ROC masing-masing model. Selain itu, ketiga model juga akan dibandingkan dengan model regresi logistik linier dan SVM non-linier berbasis data teks. Berikut Tabel 2 ditampilkan perbandingan keseluruhan model dilihat dari nilai akurasi dan AUC dari fungsi ROC:

Tabel 2 Perbandingan Model Klasifikasi

Metode	Akurasi	AUC	Jenis Model	Jenis Input
SVM	55,226%	50,055%	Unimodel	Teks
Logistic Regression	55,484%	50,288%	Unimodel	Teks
Model CNN Teks (1D)	82,320%	88,170%	Unimodel	Teks
Model CNN Gambar (2D)	98,450%	99,840%	Unimodel	Gambar
Model CNN Gabungan	99,350%	99,850%	Multimodel	Teks dan Gambar

Tabel 2, dapat disimpulkan bahwa model CNN gabungan, yang mengintegrasikan data gambar dan teks, menunjukkan kinerja yang sangat baik dalam memprediksi berita hoaks dan fakta dibandingkan dengan model-model lainnya. Model CNN gabungan mencapai akurasi sebesar 99,35% yang menunjukkan kemampuan model dalam mengklasifikasikan berita hoaks dan fakta pada data *testing*. Sementara nilai AUC sebesar 99,85%, menandakan kemampuannya yang sangat baik dalam membedakan antara berita hoaks dan fakta pada situasi di mana distribusi kelas atau ambang batas klasifikasi dapat berubah. Hal ini membuat *multimodel* berbasis gabungan foto berita dan teks berita unggul dibandingkan dengan *unimodel*.

Sementara itu, *unimodel* terbaik, yaitu model CNN berbasis gambar (model CNN 2D), memiliki akurasi yang sedikit lebih rendah, yakni 98,45% dan memiliki AUC yang lebih rendah sebesar 99,84% dibandingkan dengan *multimodel*. Secara umum, *multimodel*, khususnya Model CNN gabungan, dianggap sebagai model terbaik dalam mengklasifikasikan berita hoaks, didasarkan pada akurasi yang tinggi dalam akurasi model. Di sisi lain, SVM, *Logistic Regression*, dan Model CNN berbasis teks (1D) yang fokus pada data teks menunjukkan performa yang relatif lebih rendah. Model CNN berbasis teks (model CNN 1D) lebih baik dibandingkan dengan dua model berbasis teks menggunakan metode linier dan non-linier sebelumnya.

Selain itu model terbaik juga mengindikasikan bahwa pemanfaatan gambar foto yang telah dikategorikan lebih efektif dalam kasus ini, dimana kemampuan visual dari gambar memberikan kontribusi besar dalam membedakan antara berita hoaks dan fakta. Model-model berbasis teks mungkin memerlukan penyesuaian atau pengembangan parameter untuk meningkatkan kinerjanya dalam memprediksi berita hoaks dan fakta pada dataset yang bersangkutan. Selain itu, jumlah dan filter yang dipelajari pada model berbasis gambar lebih banyak dibandingkan dengan model berbasis teks.

V. KESIMPULAN DAN SARAN

A. Kesimpulan

Berdasarkan hasil analisis mengenai proses dalam membangun dan mengevaluasi model klasifikasi berbasis teks, gambar, dan model gabungan (*multimodal*), diperoleh kesimpulan sebagai berikut:

1. *Multimodel deep learning* atau model CNN Gabungan menunjukkan hasil evaluasi terdapat indikasi *underfit* sehingga dilakukan pengembalian nilai pada epoch ke-33, sehingga diperoleh nilai akurasi 99,35% dan nilai AUC 99,81%. Nilai akurasi berada di atas 85% menunjukkan model baik dalam mengklasifikasikan data dalam model dan nilai AUC berada di atas 85% menunjukkan model baik dalam mengklasifikasikan data di luar model.
2. Hasil analisis perbandingan *multimodel deep learning* dengan arsitektur CNN terhadap *unimodel* CNN berbasis teks dan CNN berbasis gambar menunjukkan *multimodel deep learning* lebih unggul. *Multimodel deep learning*, model CNN gabungan mampu mengungguli akurasi dan AUC *unimodel* berbasis teks SVM, Regresi Logistik, dan Model CNN 1D. Sementara model terbaik

dari kelompok *unimodel*, model berbasis gambar, model CNN 2D, memiliki nilai akurasi tertinggi dibanding *unimodel* lainnya. Berdasarkan hasil di atas mengindikasikan bahwa pemanfaatan gambar foto yang telah dikategorikan lebih efektif dalam klasifikasi berita, dimana kemampuan visual dari gambar memberikan kontribusi besar dalam membedakan antara berita hoaks dan fakta.

B. Saran

Berdasarkan kesimpulan yang diperoleh selama proses membangun dan membandingkan model CNN dapat disarankan beberapa hal sebagai berikut:

1. Hasil Evaluasi model menunjukkan model CNN gabungan menunjukkan nilai mendekati sempurna dengan tingkat akurasi 99,35% yang dinilai terlalu tinggi. Sehingga diperlukan penelitian lebih lanjut untuk mengetahui apakah akurasi model tetap tinggi atau menurun dengan memperbanyak *epoch*, jumlah data *training*, dan *testing*.
2. Model CNN 2D dan gabungan menunjukkan nilai akurasi hampir sama namun berbeda jika dibandingkan dengan model CNN 1D. Hal tersebut menunjukkan terdapat kemungkinan dataset yang melibatkan gambar lebih mudah dikenali oleh mesin atau data mirip satu sama lain, sehingga disarankan untuk *training* model menggunakan data berita hoaks dan fakta berbasis teks yang lebih beragam untuk mengimbangi model berbasis gambar.

DAFTAR PUSTAKA

- [1] V. Mazaya, "Cyberdakwah sebagai Filter Penyebaran Hoax," *Islamic Communication Journal*, pp. 4(1), 14-25., 2019.
- [2] 6 April 2023. [Online]. Available: https://www.kominfo.go.id/content/detail/48363/siaran-pers-no-50hmkominfo042023-tentang-triwulan-pertama-2023-kominfo-identifikasi-425-isu-hoaks/0/siaran_pers.
- [3] R. P. J. M. Y. W. H. A. & Y. A. Harnum, "Sosialisasi Buku Saku Tangkal Hoaks Covid-19 untuk Mahasiswa Sebagai Agent of Change," *Journal of Servite*, pp. 4(2), 91-103., 2022.
- [4] D. A. & A. R. Pranesti, "Pranesti, Dewi Ayu, and Ridwan Arifin. "Perlindungan Korban dalam Kasus Penyebaran Berita Hoax di Media Sosial di Indonesia.," *Jurnal Hukum Media Bhakti*, 2019.
- [5] K. I. Huroh, "Penekanan Penyebaran hoax DI Media Sosial Sebagai upaya meningkatkan Persatuan Negara Indonesia.," *Jurnal Kalacakra: Ilmu Sosial Dan Pendidikan*, pp. 3(2), 72. <https://doi.org/10.31002/kalacakra.v3i2.6377>, 2022.
- [6] C. N. N. &. Siahaan and M. Tampubolon, "Strategy for identification of hoax news in digital media in facing case of racism of Papua students in Indonesia," *Technium Social Sciences Journal*, pp. 21, 457–467. <https://doi.org/10.47577/tssj.v2i1.3959> , 2021.
- [7] M. & S. P. Dulkiah, "Pola Penyebaran Hoaks pada Kalangan Mahasiswa Perguruan Tinggi Islam di Kota Bandung," *Jurnal SMART (Studi Masyarakat, Religi, Dan Tradisi)*, pp. 6(2), 1-16., 2020.
- [8] J. I. M. H. M. S. L. T. & A. W. Simarmata, Hoaks dan media sosial: saring sebelum sharing, Yayasan Kita Menulis, 2019.
- [9] A. N. & C. D. A. Dilla, "Komunikasi Persuasif dalam Kampanye Gerakan Anti Hoaks oleh Komunitas Mafindo Jakarta," *Koneksi*, pp. 3(1), 199-206., 2019.
- [10] E. & N. M. Asriyar, "Aplikasi Machine Learning Issue Detection and Alert System Dengan Menggunakan Metode K-Nearest Neighbors Pada PT Andalabs," *JI-Tech*, pp. 15(1), 1-7., 2019.
- [11] R. P. A. P. & P. A. Yunanto, "Survei Literatur: Deteksi Berita Palsu Menggunakan Pendekatan Deep Learning," *Jurnal Manajemen Informatika (JAMIKA)*, pp. 11(2), 118-130., 2021.
- [12] T. N. & S. H. P. (. Hawari, "Analisis Kriminologis Penggunaan News Picture dalam Hoax yang Tersebar di Media Sosial (Analisis Isi Hoax pada Turnbackhoax. Id)," *Deviance Jurnal kriminologi*, pp. 3(2), 91-109., 2019.
- [13] L. L. O. H. P. & B. D. A. Li, " A multi-modal method for satire detection using textual and visual cues," *arXiv preprint arXiv*, p. 2010.06671., 2020.
- [14] A. A. & M. M. (. Kurniawan, " Implementasi Deep Learning Menggunakan Metode CNN dan LSTM untuk Menentukan Berita Palsu dalam Bahasa Indonesia," *Jurnal Informatika Universitas Pamulang*, pp. 5(4), 544-552., 2021.
- [15] S. S. S. & M. Z. Yuliani, "Hoax News Classification using Machine Learning Algorithms," *International Journal of Engineering and Advanced Technology*, pp. 9(2), 2249-8958, 2019.
- [16] F. A. F. & I. M. Ofli, "Analysis of social media data using multimodal deep learning for disaster response," *arXiv preprint arXiv*, p. 2004.11838, 2020.
- [17] A. & A. S. Haqqo, "Turnbackhoax. id: Upaya Pemutusan Disinformasi Berita-berita Pemilu 2024.," *Indonesian Journal of Applied Linguistics Review*, pp. 4(1), 9-18., 2023.
- [18] Z. A. & Y. N. Zaen, "ANALISIS FRAMING TENTANG PANDAWARA GROUP DAN PEMERINTAH SUKABUMI TERKAIT PANTAI LOJI PADA MEDIA ONLINE KOMPAS. COM DAN REPUBLIKA. CO. ID," *Triwikrama: Jurnal Ilmu Sosial*, 2023.
- [19] M. Djufri, "Penerapan Teknik Web Scraping Untuk Penggalian Potensi Pajak (Studi Kasus Pada Online Market Place Tokopedia, Shopee Dan Bukalapak)," *Jurnal BPPK: Badan Pendidikan Dan Pelatihan Keuangan*, pp. 13(2), 65-75., 2020.

- [20] A. R. N. M. K. S. O. S. & Z. E. M. Lubis, "The effect of the TF-IDF algorithm in times series in forecasting word on social media. Indones," *J. Electr. Eng. Comput.*, pp. Sci, 22(2), 976., 2021.
- [21] S. & A. R. Qaiser, "Text mining: use of TF-IDF to examine the relevance of words to documents," *International Journal of Computer Applications*, pp. 181(1), 25-29., 2018.
- [22] M. K. M. R. & P. P. Sewak, Practical convolutional neural networks: implement advanced deep learning models using Python, Packt Publishing Ltd., 2018.
- [23] N. K. U. T. & H. S. I. Sugiarto, "PEMODELAN HYBRID CONVOLUTIONAL BACKPROPAGATION NEURAL NETWORK UNTUK PERAMALAN BEBAN JANGKA SANGAT PENDEK BERDASARKAN MINIMALISASI BIAYA LISTRIK," *JURNAL TEKNIK ELEKTRO*, pp. 10(2), 463-472., 2021.
- [24] J. W. Z. K. J. M. L. S. A. S. B. ... & C. T. Gu, "Recent advances in convolutional neural networks," *Pattern recognition*, pp. 77, 354-377, 2018.
- [25] M. R. & W. A. T. Assegaf, "Klasifikasi Spesies Tanaman Monstera Berdasarkan Citra Daun Menggunakan Metode Convolutional Neural Network (Cnn)," *eProceedings of Engineering*, p. 8(4)., 2021.
- [26] E. & M. K. F. Kim, "Multimodal deep learning using images and text for information graphic classification," *In Proceedings of the 20th International ACM SIGACCESS Conference on Computers and Accessibility*, pp. (pp. 143-148)., 2018.
- [27] J. L. J. W. C. W. H. Z. C. & T. G. Zhou, "Crop disease identification and interpretation method based on multimodal deep learning," *Computers and Electronics in Agriculture*, pp. 189, 106408., 2021.
- [28] H. R. Y. & A. M. Mouzannar, "Damage Identification in Social Media Posts using Multimodal Deep Learning," *In ISCRAM.*, 2018.